Analiza klasifikacionih modela na ISOLET skupu podataka

Autor: Angelina Jordanov
Kurs: Istraživanje podataka 2

Sadržaj

1 Uvod …….3

2 Opis i priprema podataka ……. 3

2.1 Detekcija i analiza outliera …….……...3

2.2 Skaliranje podataka ……..4

2.3 Vizuelizacija podataka …….4

3 Odabir podskupova za klasifikaciju ……..….5

3.1 PCA redukcija dimenzionalnosti …….5

3.2 Feature selection na osnovu Random Forest-a …….……...6

4 Primena klasifikacionih algoritama ……...…….7

4.1 Decision Tree Classifier (DTC)….……..……7

4.2 Random Forest Classifier …….….……...8

4.3 K-Nearest Neighbors (KNN) …….……..9

4.4 Support Vector Machine (SVM) ……...….……10

4.5 Gradient Boosting Classifier (GBC) …….…….11

4.6 Poređenje modela …….……..11

5 Zaključak …….……..…14

6 Literatura …….…….…15

1 Uvod

U ovom radu bavićemo se problemom klasifikacije, koji spada u nadgledane metode mašinskog učenja. Klasifikacijom se na osnovu trening podataka modeli obučavaju da prepoznaju karakteristike među njima, a zatim se ti modeli koriste za razvrstavanje novih ulaznih podataka u odgovarajuće kategorije.

Cilj ovog rada je primena i poređenje različitih klasifikacionih algoritama nad ISOLET skupom podataka. ISOLET predstavlja kolekciju zvučnih zapisa predstavljenih numeričkim atributima. Svaki zvučni zapis predstavlja po jedno izgovoreno slovo engleskog alfabeta. Uzorci su prikupljeni od većeg broja ispitanika. Pored primene različitih algoritama, u radu će biti analiziran i uticaj različitih pristupa obradi atributa na kvalitet klasifikacije, kao i performanse posmatranih modela.

2 Opis i priprema podataka

Kao što je pomenuto u prethodnom poglavlju, u ovom radu koristi se ISOLET skup podataka. Prema dostupnom opisu skupa, podaci ne sadrže nedostajuće vrednosti, a to je i dodatno provereno u okviru implementacije projekta. Skup je formiran tako što je 150 ispitanika izgovorilo svih 26 slova engleskog alfabeta dva puta. Na osnovu toga očekivani broj instanci iznosi 7800, međutim ovaj skup sadrži ukupno 7797. Prema opisu autora skupa nekoliko instanci je izostavljeno usled poteškoća tokom snimanja zvuka.

Podaci su organizovani u pet različitih grupa, pri čemu svaka grupa sadrži po 30 ispitanika i sve njihove zvučne zapise. Prve četiri grupe objedinjene su u jedan skup i koristimo ih kao trening podatke, dok je peta grupa izdvojena i koristimo je kao test skup.

Obzirom na to da su svi ispitanici izgovorili sva slova isti broj puta, svaki od pet delova, kao i njihove kombinacije, možemo smatrati balansiranim u pogledu zastupljenosti klasa. Na Slici 1 prikazana je raspodela klasa u trening skupu. Možemo uočiti da je zastupljenost svih kategorija ista (uz minimalno odstupanje), odnosno skup je balansiran.

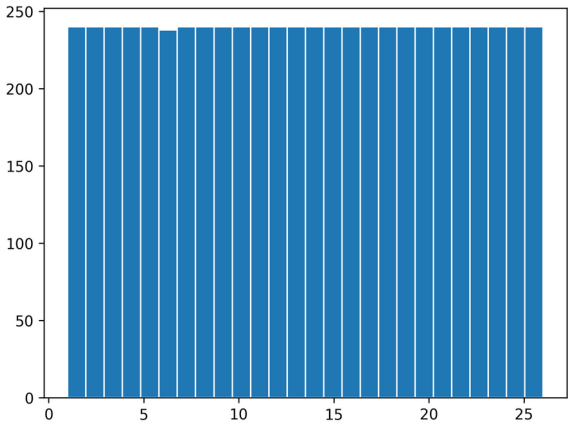

Slika 1: Balansiranost zastupljenosti klasa

2.1 Detekcija i analiza outliera

U okviru pripreme podataka uradili smo i proveru javljanja ekstremnih vrednosti i potencijalnih outliera. Za ovu analizu korišćen je boxplot prikaz nad podskupom podataka (Slika 2). Na boxplot dijagramu svaka kolona sadrži ”kutiju”, čije donja i gornja ivica odgovaraju prvom kvartilu (Q1) i trećem kvartilu (Q3). Interval između Q1 i Q3 predstavlja interkvartilni raspon (IQR), u kome se nalazi centralnih 50% podataka. Iz kutije se dalje prostiru takozvani ”brkovi”, čije se granice najčešće određuju formulama:

- donja granica: $Q1 - 1.5 \cdot IQR$
- gornja granica: $Q3 + 1.5 \cdot IQR$

Vrednosti koje se nalaze izvan tih granica prikazuju se kao pojedinačne tačke i označavaju potencijalne outliere.

Na nekim od posmatranih atributa primećen je veći broj takvih vrednosti. Međutim, s obzirom na prirodu ISOLET skupa podataka, ove pojave ne moraju predstavljati greške ili šum u podacima. Verovatnije je da su posledica prirodnih razlika među govornicima, kao što su boja glasa, način izgovora, jačina govora, pol ispitanika ili specifičnosti pojedinih slova. Zbog toga ove vrednosti nismo uklonili iz skupa podataka.

Slika 2: Boxplot prikaz prvih 20 atributa ISOLET skupa podataka

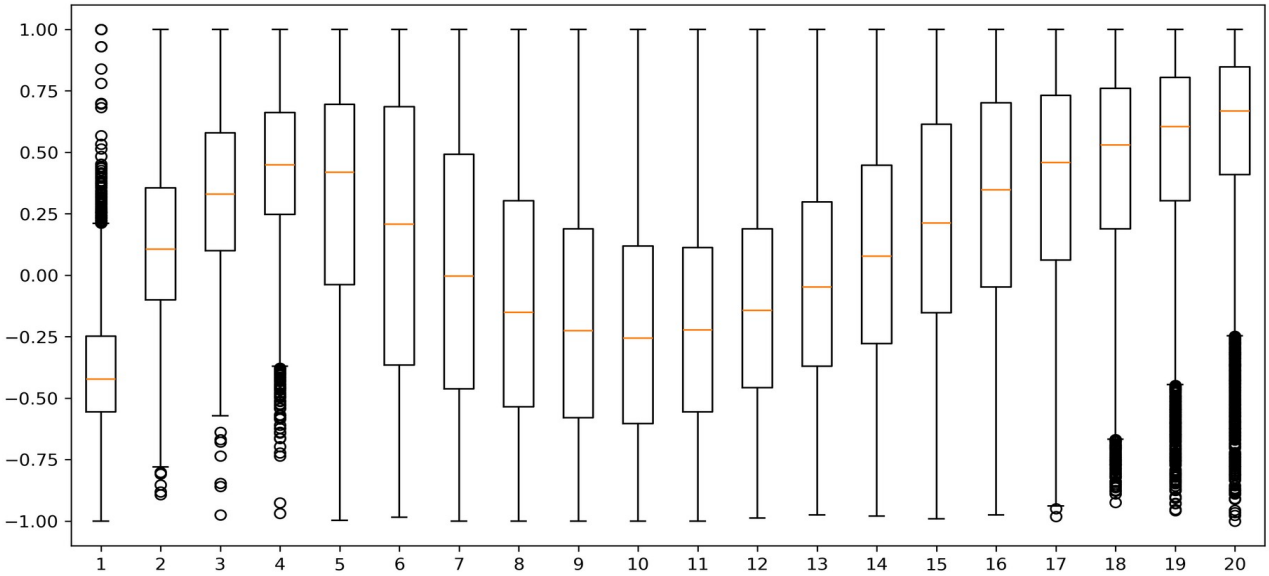

2.2 Skaliranje podataka

Iako su vrednosti svih atributa već bile u opsegu od −1 do 1, primenjen je StandardScaler. Ova transformacija, poznata i kao Z-score standardizacija, prilagođava vrednosti svakog atributa tako da nakon transformacije imaju srednju vrednost približno 0 i standardnu devijaciju približno 1. Ovaj postupak je bitan jer isti numerički opseg ne garantuje i istu raspodelu vrednosti. Na primer, možemo imati slučaj da su vrednosti jednog atributa grupisane oko nule, dok kod drugog mogu biti više koncentrisane krajevima intervala. U tom slučaju pojedini atributi mogu imati veći uticaj kod određenih modela, iako nisu nužno informativniji za problem klasifikacije. Zbog toga je nad trening podacima primenjena standardizacija, kako bi se obezbedio ravnomerniji uticaj svih atributa.

2.3 Vizuelizacija podataka

Vizuelizacija ulaznih podataka najpre je izvršena primenom PCA metode. Ova metoda se generalno koristi za smanjenje dimenzionalnosti podataka, a može se koristiti kao deo pripreme podataka za treniranje modela. Pri transformaciji teži da zadrži što više informacija iz originalnog prostora. Primer vizuelizacije pomoću PCA prikazan je na Slici 3, gde su korišćene dve glavne komponente nad uzorkom od 2000 instanci trening skupa. Na dobijenom prikazu može se uočiti da su pojedine klase delimično izdvojene, dok se značajan broj njih i dalje preklapa, pa razdvajanje nije dovoljno jasno.

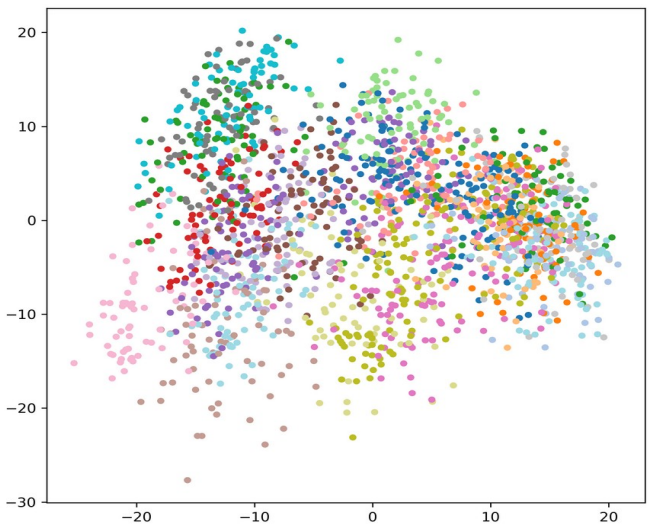

Slika 3: Prikaz podataka s dve PCA komponente

Zbog toga je dodatno primenjena metoda t-SNE. Za razliku od PCA, ova metoda je primarno namenjena vizuelizaciji podataka i u tu svrhu teži da međusobno slične instance prikaže bliže jedne drugima, dok različite instance razdvaja u većoj meri. Time se dobija pregledniji prikaz strukture podataka čiji je primer dat na Slici 4 za isti podskup koji je korišćen i za PCA.

Na t-SNE vizuelizaciji mogu se uočiti jasnije formirane grupe instanci, što ukazuje da u podacima postoji određena struktura i razdvojenost klasa. Takav raspored sugeriše da skup podataka predstavlja dobru osnovu za primenu klasifikacionih algoritama.

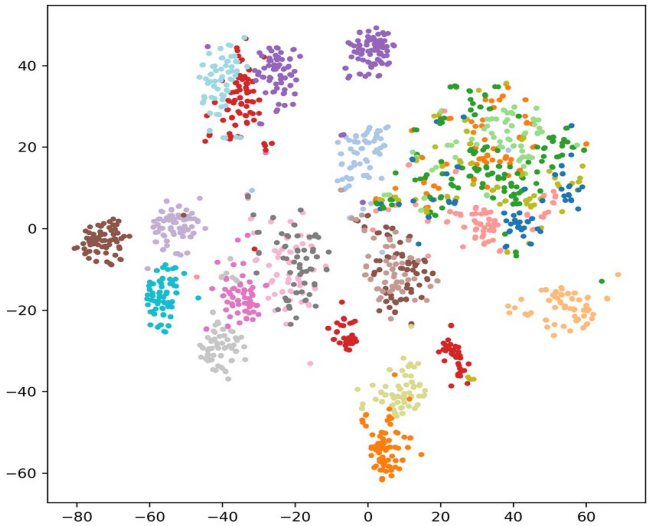

Slika 4: Prikaz podataka pomoću t-SNE metode

3 Odabir podskupova za klasifikaciju

Skup podataka sadrži preko 600 atributa što predstavlja visoku dimenzionalnost i može negativno uticati na performanse ali i efikasnost nekih klasifikacionih algoritama. Zbog toga smo napravili i redukovane skupove atributa i ispitali kako njihovo korišćenje utiče na vreme treniranja i tačnost modela. Odnosno, svaki od algoritama testiran je na tri različite varijante ulaznih podataka:

1. kompletan skup atributa
2. skup redukovan PCA transformacijom
3. skup odabranih najznačajnijih atributa na osnovu feature importance iz Random Forest modela

3.1 PCA redukcija dimenzionalnosti

Primena PCA metode je izvršena u cilju smanjenja broja atributa uz očuvanje što većeg dela informacija iz originalnog skupa. Testirali smo 70 glavnih PCA komponenti, pri čemu je analizirana kumulativna objašnjena varijansa. U Tabeli 1 prikazan je njen postepeni rast u odnosu na broj komponenti.

Na osnovu prikazane krive (Slika 5) uočavamo da se na oko 25 komponenti nalazi tačka nakon koje se porast objašnjene varijanse značajno usporava. U toj tački objašnjeno je oko 60% ukupne varijanse, što ukazuje da bi značajan deo informacija bio izgubljen pri izboru tako malog broja komponenti. Zbog toga je broj PCA komponenti povećan na 50, čime se objašnjava približno 80% varijanse, što predstavlja kompromis između smanjenja dimenzionalnosti i očuvanja informacija.

Tabela 1: Odnos broja komponenti i varijanse

Components	Variance
10	54%
30	73%
50	80.5%
70	84.9%

Slika 5: Kumulativna objašnjena varijansa za 70 PCA komponenti

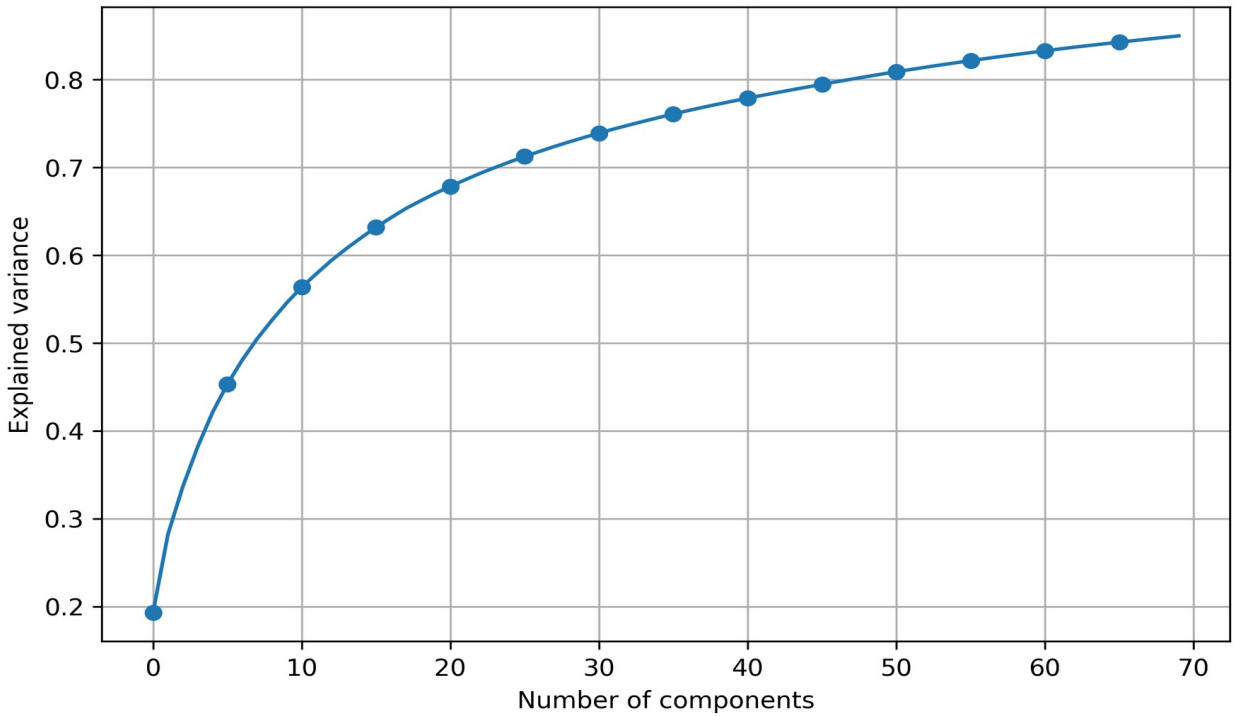

3.2 Feature selection na osnovu Random Forest-a

Pored PCA metode, korišćena je i selekcija atributa pomoću Random Forest modela. Ovaj pristup nam omogućava da pronađemo one atribute koji najviše utiču na ciljnu promenljivu. Na taj način izdvajamo najbitnije karakteristike i smanjujemo broj ulaznih atributa.

Testirali smo različite vrednosti broja izabranih atributa što je prikazano u Tabeli 2. U njoj smo uporedili broj odabranih najvažnijih atributa sa ostvarenom tačnošću Random Forest modela. Rezultati pokazuju da se tačnost postepeno povećava sa porastom broja atributa: za 50 atributa iznosi 89%, za 100 atributa 91%, dok se za 150 i 200 atributa dostiže približno ista vrednost od oko 93.58%. Korišćenjem svih atributa postiže se blago viša tačnost od 94%, ali uz znatno veću dimenzionalnost podataka.

Tabela 2: Uticaj broja selektovanih komponenti na tačnost modela

Features	Test accuracy
50	89%
100	91%
150	93.58%
200	93.58%
All features	94%

Na osnovu prikazanih rezultata, izabran je skup od 150 najvažnijih atributa kao optimalan za dalje eksperimente. Ovaj broj atributa omogućava ostvarivanje tačnosti koje su veoma bliske korišćenju kompletnog skupa podataka, uz istovremeno značajno smanjenje dimenzionalnosti ulaznog prostora.

4 Primena klasifikacionih algoritama

U ovom radu korišćeno je pet različitih klasifikacionih algoritama kako bi se uporedile njihove performanse i tačnosti. Takođe, pored rada ovih modela na originalnom skupu ispitaćemo i kako različiti modeli reaguju na PCA transformaciju i selektovane atribute.

4.1 Decision Tree Classifier (DTC)

Prvi korišćeni algoritam bio je Decision Tree Classifier. Ovaj model generiše drvoliku strukturu gde svaki unutrašnji čvor predstavlja proveru nekog atributa, a listovi predstavljaju konačne klase. Tokom izgradnje stabla, u svakom koraku se bira atribut koji najbolje razdvaja podatke. Taj postupak se zatim ponavlja rekurzivno nad novonastalim granama, sve dok se ne ispuni barem jedan od uslova zaustavljanja (npr. da svi primeri u čvoru pripadaju istoj klasi). Proces klasifikovanja nove instance kreće od korenog čvora, a potom se u zavisnosti od vrednosti atributa prati odgovarajuća grana sve dok se ne stigne do lista koji daje predikciju klase. Za razliku od nekih drugih modela ovaj algoritam nije posebno osetljiv na različite razmere atributa, pa nije neophodna standardizacija podataka.

Najpre smo model trenirali sa podrazumevanim postavkama parametara. Međutim, dobijena tačnost na trening skupu bila je 100%, dok je tačnost na test skupu iznosila 79.7%. Ovakav rezultat ukazuje na izražen overfitting, jer je model gotovo savršeno naučio trening podatke, ali se slabije pokazao na novim podacima. Zbog toga smo primenili GridSearchCV kako bismo pronašli bolju kombinaciju hiperparametara. Ispitivali smo kriterijume podele (gini i entropy), kao i maksimalnu dubinu stabla (10, 15 i 20). Najbolji rezultat postignut je sa parametrima koji kao kriterijum koristi entropiju a dozvoljena maksimalna dubina stabla je 20. Tada je tačnost na trening skupu ostala 100%, dok je test tačnost porasla na 81.5%. Iako je došlo do poboljšanja, overfitting je i dalje bio prisutan u velikoj meri. Iz tog razloga smo podesili dodatne parametre min_samples_split i min_samples_leaf, koji određuju minimalan broj uzoraka potreban za dalje grananje i minimalan broj uzoraka u listovima. Na taj način model je dodatno ograničen kako ne bi pravio previše složeno stablo. Najbolji dobijeni parametri bili su:

- criterion = entropy
- max_depth = 15
- min_samples_leaf = 5
- min_samples_split = 15

Dobijena je trening tačnost 93.2%, dok je test tačnost porasla na 82.8%. Iako je poboljšanje test tačnosti bila relativno mala, značajno je to što je razlika između trening i test rezultata smanjena. Time je model postao stabilniji i manje preprilagođen.

Na ovoj postavci modela analizirali smo i performanse uz primenu PCA i metode feature selection. Kod PCA pristupa ostvarena je tačnost od 86.8% na trening skupu i 68.4% na test skupu. Velika razlika između trening i test tačnosti ukazuje na lošu generalizaciju modela. Iako se na prvi pogled može pomisliti na overfitting, ovde je verovatno doprinelo i to što se PCA projekcijom gube značajane informacija potrebnih za klasifikaciju, što dovodi do dodatnog pada performansi na neviđenim podacima.

Sa druge strane, feature selection daje znatno bolje rezultate: 92.6% na trening skupu i 82.7% na test skupu. Tačnost na test skupu je bliska onoj dobijenoj na celom skupu podataka, što sugeriše da odabrani podskup atributa uspešno zadržava ključne informacije iz originalnog skupa. Pored toga, smanjenje dimenzionalnosti ovom metodom doprinosi nižoj vremenskoj i memorijskoj složenosti modela. Na osnovu ovih rezultata, može se zaključiti da je u ovom slučaju feature selection pogodniji pristup od PCA, jer postiže bolji balans između tačnosti i generalizacije, uz manju kompleksnost modela.

Tabela 3: DTC rezultat klasifikacije

	Training acc	**Test acc**	**Time**
Full data	93.2 %	82.8 %	12s
PCA	86.8 %	68.4 %	1s
FS	92.6 %	82.7 %	3s

4.2 Random Forest Classifier

Random Forest je ansambl metoda koja se sastoji od većeg broja stabala odlučivanja treniranih na različitim podskupovima podataka za treniranje. Spada u grupu bagging klasifikatora, što znači da se više modela trenira paralelno, a zatim zajedno učestvuju u donošenju konačne odluke. Rezultat dobija glasanjem svih stabala, pri čemu klasa sa najviše glasova postaje konačna predikcija.

Model smo prvo testirali sa podrazumevanim parametrima biblioteke, pri čemu je broj stabala bio 100. Ovom postavkom dobijena je tačnost na trening skupu 100% a na test skupu između 94% i 95% za različite seed vrednosti, što ukazuje na stabilnost modela. Pokušali smo i blagi fine-tuning bitnijih parametara, povećanje broja stabala na 200 i ograničavanje dubine stabala (15, 20, 25). Ipak, tačnost na test skupu nije porasla ni za 1%, stoga smo odlučili da zadržimo osnovnu konfiguraciju modela sa 100 stabala i ostalim podrazumevanim parametrima.

Rezultati nad drugim podskupovima prikazani su u Tabeli 4. Tačnost na trening skupu iznosi 100% za sva tri slučaja, dok su rezultati na test skupu slični za model treniran na celokupnom skupu podataka i onaj dobijen primenom feature selection metode. U slučaju PCA reprezentacije uočava se blagi pad tačnosti do približno 3% u odnosu na ostale pristupe. Vreme treniranja za sve modele je manje od pola minuta, što ukazuje da je proces obuke brz i stabilan na ovom datasetu. Na osnovu dobijenih rezultata, kao najbolji model može se izdvojiti onaj treniran na celokupnom skupu podataka, s obzirom na to da ostvaruje najvišu tačnost na test skupu, uz zadržavanje sličnih vremenskih performansi u odnosu na ostale pristupe.

Tabela 4: RandomForest rezultati klasifikacije

	Training acc	**Test acc**	**Time**
Full data	100 %	94.0 %	18s
PCA	100 %	90.6 %	7s
FS	100 %	93.6 %	9s

4.3 K-Nearest Neighbors (KNN)

KNN predstavlja jednostavan klasifikacioni algoritam zasnovan na poređenju sličnosti između instanci. Ovaj model je deterministički, što znači da za iste ulazne podatke uvek daje isti izlaz i ne oslanja se na nasumične elemente tokom rada. Princip rada algoritma zasniva se na pronalaženju k najbližih suseda posmatrane instance u prostoru atributa. Nakon toga se proverava kojoj klasi pripadaju pronađeni susedi, a instanci se dodeljuje ona klasa koja se među susedima pojavljuje najčešće. Bliskost između instanci određuje se pomoću izabrane metrike rastojanja, kao što su euklidsko ili Menhetn rastojanje.

Pri korišćenju difoltnih vrednosti parametara naš model je ostvario tačnost od 92.8% na trening skupu i 91.1% na test skupu. Na osnovu male razlike između ova dva rezultata može se zaključiti da nije bilo overfittinga.
U cilju poboljšanja performansi izvršena je optimizacija hiperparametara primenom metode Grid Search. Testirani su sledeći parametri:

- broj suseda: 5, 7, 9, 11
- ”jačina” glasa suseda (weights): uniformno (svaki glas jednako bitan) i težinsko (bliži susedi imaju jači uticaj)
- parametar p za Minkowski metriku:
    - p = 1 (Menhetn rastojanje)
    - p = 2 (Euklidsko rastojanje)

Najbolja pronađena kombinacija parametara bila je:

- broj suseda = 9
- weights = težinsko
- p = 2

Sa ovim podešavanjem model je ostvario tačnost od 100% na trening skupu i 92.6% na test skupu. Što znači da je nakon optimizacije hiperparametara dobijeno poboljšanje tačnosti na test skupu za nešto više od 1%. Trening tačnost od 100% ukazuje na blago preprilagođavanje kod podataka za treniranje, ali s obzirom na bolje rezultate nad test skupom, izabrali smo optimizovanu konfiguraciju modela za dalju analizu.

Rezultati koje model ostvaruje i na ostalim skupovima podataka (PCA i feature selection) prikazani su u Tabeli 5. Može se uočiti da je vreme treniranja za sve podskupove bilo veoma kratko. To je posledica toga što KNN više vremena troši u fazi klasifikacije nego u fazi treniranja za rezliku od ostalih algortiama. Najbolji rezultati postignuti su nad skupom dobijenim primenom feature selection metode, dok je model treniran nad celokupnim skupom podataka ostvario veoma slične performanse sa približno 1% nižom tačnošću. Ovakvo ponašanje je očekivano kod KNN algoritma, jer prisustvo većeg broja manje relevantnih atributa može otežati računanje rastojanja između instanci, pa pažljivo odabrani podskup karakteristika može doprineti boljoj klasifikaciji.

Tabela 5: KNN rezultati klasifikacije

	Training acc	**Test acc**	**Time**
Full data	100 %	92.6 %	<1s
PCA	100 %	90.8 %	<1s
FS	100 %	93.6 %	<1s

4.4 Support Vector Machine (SVM)

SVM je klasifikacioni algoritam koji pokušava da pronađe granicu koja najbolje razdvaja instance različitih klasa. Kod linearno razdvojivih podataka ova granica je prava linija odnosno ravan u višim dimenzijama. Međutim, u većini realnih problema podaci nisu linearno razdvojivi, pa se koriste kernel funkcije koje omogućavaju preslikavanje podataka u višu dimenziju, gde se klase mogu lakše razdvojiti.

U okviru ovog rada testirali smo sva tri kernela (linearni, RBF i polinomski) i sva tri su se solidno pokazala. Njihovi rezultati ocena dati su u Tabeli 6. Zbog najviše tačnosti koja iznosi 96.2% na test podacima, male razlike izmedju tačnosti trening i test podataka, ali i prirode problema odlucili smo da je za naš dalji rad najprikladniji RBF kernel.

U daljoj analizi vršeno je podešavanje hiperparametra C, koji kontroliše koliko model ”kažnjava” greške na trening podacima. Manje vrednosti C dovode do jednostavnijeg modela koji više toleriše greške, dok veće vrednosti C pokušavaju da što bolje prilagode model trening podacima. Podrazumevana vrednost ovog parametra je C = 1. Dobijeni rezultati su:

- C = 0.01 - trening 93.3%, test 92.5%
- C = 10 - trening 100%, test 96.4%
- C = 100 - isti kao prethodno

Može se primetiti da povećanjem vrednosti C model bolje uči trening podatke, ali poboljšanje na test skupu je relativno malo. Iako dolazi do blagog preprilagođavanja, performanse na test skupu ostaju visoke.
Na osnovu svih rezultata, kao finalna konfiguracija SVM modela izabrali smo RBF kernel sa parametrom C = 10, jer ova kombinacija daje najviše i dovoljno stabilne rezultate na test podacima.

Rezultati ove postavke modela za sve podatke, PCA komponente i skup atributa dobijen feature selection metodom prikazani su u Tabeli 7. Najveiša tačnost ostvarena je pri korišćenju kompletnog skupa podataka. Vreme treniranja u tom slučaju iznosilo je 7 sekundi, što je duže u odnosu na preostala dva pristupa, kod kojih je treniranje trajalo manje od jedne sekunde. Ipak, i pored toga, vreme od 7 sekundi predstavlja veoma brzo i efikasno izvršavanje modela. Na osnovu navedenih rezultata može se zaključiti da je za primenjeni SVM model, na posmatranom skupu podataka, najisplativije koristiti sve raspoložive atribute, jer se time postiže najbolja tačnost uz i dalje veoma kratko vreme treniranja.

Tabela 6: Poređenje kernela za SVM

	Training acc	**Test acc**
linear	100 %	95.6 %
RBF	99.6 %	96.2 %
poly	99.3 %	96.1 %

Tabela 7: SVM rezultati klasifikacije

	Training acc	**Test acc**	**Time**
Full data	100 %	96.4 %	7s
PCA	100 %	94.9 %	<1s
FS	100 %	94.9 %	<1s

4.5 Gradient Boosting Classifier (GBC)

GBC pripada ansambl metodama i koristi princip boostinga, odnosno više modela koji se treniraju redom. Svaki naredni model uči na greškama prethodnog i pokušava da ih ispravi, pa se tako postepeno dobija sve precizniji konačni model. Kao osnovni modeli najčešće se koristie manja stabla odlučivanja, pa je osnova algoritma slična Decision Tree Classifier-u. Gradient Boosting se razlikuje od drugih boosting metoda po tome što svaki novi model uči rezidualne greške prethodnog modela i minimizuje funkciju greške pomoću gradijenta, umesto da samo povećava značaj pogrešno klasifikovanih primera.

Testirali smo model za dve različite vrednosti estimatora i merili vreme treniranja. Za 100 estimatora dobijena je tačnost 100% na trening skupu i 92% na test skupu dok je vreme izvršavanja bilo oko sat vremena, a za 30 estimatora dobijeno 99.5% na trening skupu, 90.6% na test skupu i oko 18 minuta je bilo potrebno za treniranje. Iako veći broj estimatora može dati nešto bolje rezultate, vreme treniranja je značajno duže. Zbog toga je vrednost 30 estimatora realističnija i efikasnija za praktičnu primenu, jer daje vrlo sličnu tačnost uz manju računarsku složenost.

Ovu postavku modela primenili smo i na PCA komponente, pri čemu je ostvarena tačnost od 95.8% na trening skupu i 80% na test skupu, uz vreme izvršavanja od približno dva minuta. Kod primene na izdvojenom skupu atributa dobijenom metodom feature selection, postignuta je tačnost od 98.8% na trening skupu i 90.6% na test skupu, uz vreme izvršavanja od oko 4.5 minuta.

Svi navedeni rezultati prikazani su u Tabeli 8. Iako je primena PCA donela najkraće vreme izvršavanja, došlo je do pada tačnosti od čak 10%. Kod metode feature selection ostvareni su isti rezultati tačnosti kao pri korišćenju svih atributa, ali uz približno četiri puta kraće vreme izvršavanja. Stoga možemo zaključiti da se metoda feature selection pokazala kao najbolji kompromis između tačnosti i vremena izvršavanja kod ovog modela.

Tabela 8: GBC rezultati klasifikacije

	Training acc	**Test acc**	**Time**
Full data	99.5 %	90.6 %	18 min
PCA	95.8 %	80.0 %	2.3 min
FS	98.8 %	90.6 %	4.5 min

4.6 Poređenje modela

U ovom poglavlju prikazani su i upoređeni rezultati svih primenjenih klasifikacionih modela na tri različite reprezentacije podataka: celokupan skup, PCA transformaciju i feature selection. Cilj je analiza uticaja redukcije i izbora atributa na performanse modela.

Na osnovu rezultata dobijenih na celokupnom skupu podataka (Tabela 9), može se uočiti jasna razlika u performansama primenjenih modela klasifikacije. DTC ostvaruje najnižu tačnost od 82.8%, što ukazuje na to da ovaj model, iako jednostavan, ima ograničenu sposobnost generalizacije na ovom problemu. Random Forest postiže 94%, što pokazuje da kombinovanje više stabala daje stabilnije i tačnije rezultate u odnosu na pojedinačno stablo odlučivanja. Iako takođe spada u ansambl metode, GBC postiže nešto nižu tačnost koja iznosi 90.6%. Ovo može biti posledica specifičnosti podataka ili podešavanja parametara. KNN model ostvaruje 92.6% tačnosti, dok najbolje rezultate

Tabela 9: Rezultati svih modela nad celim skupom atributa

Model	**Test accuracy**
DTC	82.8 %
RF	94.0 %
KNN	92.6 %
SVM	96.4 %
GBC	90.6 %

postiže SVM sa tačnošću od 96.4%. Iz ovoga možemo zaključiti da su slične instance dobro grupisane ali i dobro razdvojive u prostoru karakteristika.

Nakon primene PCA transformacije (Tabela 10), uočava se opšti pad performansi modela u poređenju sa rezultatima na celokupnom skupu podataka. Pad od preko 10% prisutan je kod DTC i GBC modela koji su se ovde najlošije pokazali. Random Forest i KNN daju vrlo slične visoke rezultate, što pokazuje da oba modela dobro koriste informacije zadržane kroz PCA transformaciju. Najbolji rezultat ponovo ostvaruje SVM sa 94.9%, što potvrđuje njegovu stabilnost i efikasnost i u prostoru smanjenog broja komponenti, gde i dalje uspešno razdvaja klase.

Tabela 10: Rezultat svih modela nad PCA komponentama

Models	Test accuracy
DTC	68.4 %
RF	90.6 %
KNN	90.8 %
SVM	94.9 %
GBC	80.0 %

Tabela 11: Rezultat svih modela nad FS podskupom atributa

Models	Test accuracy
DTC	82.7 %
RF	93.6 %
KNN	93.6 %
SVM	94.9 %
GBC	90.6 %

Analizom rezultata dobijenih primenom feature selection pristupa (Tabela 11) može se uočiti da se performanse modela generalno stabilizuju u odnosu na prethodnu transformaciju. SVM ponovo ostvaruje najbolji rezultat sa 94.9%, što pokazuje da izbor relevantnih atributa ne utiče značajno na njegovu sposobnost razdvajanja klasa. Random Forest i KNN postižu identičnu tačnost od 93.6%, pri čemu KNN u ovom slučaju ostvaruje svoj najbolji rezultat u odnosu na prethodne eksperimente, što sugeriše da redukcija broja atributa može pozitivno uticati na njegov rad. DTC i GBC zadržavaju rezultate slične onima na celokupnom skupu podataka. Sveukupno, može se zaključiti da feature selection ne menja značajno rangiranje modela, ali doprinosi stabilnijim i ujednačenijim rezultatima kod većine algoritama dok štedi performanse.

Detaljnije ćemo uporediti naš najbolji (SVM) i najslabiji (DTC) model. Ovo poređenje može biti posebno zanimljivo jer je jedan model baziran na matematičkoj optimizaciji a drugi na donošenju odluka kroz grananje atributa. Na Slici 6 prikazana je matrica konfuzije SVM modela nad celokupnim skupom podataka. Uočavamo da su vrednosti van glavne dijagonale uglavnom veoma male, što ukazuje na mali broj pogrešno klasifikovanih instanci. Sa druge strane, elementi na glavnoj dijagonali imaju visoke vrednosti, što potvrđuje da model uspešno klasifikuje najveći deo uzoraka u odgovarajuće klase. Analizom classification report-a (Tabela 12) pokazuje se da određene klase ostvaruju savršene rezultate (slova: A, H, J, L, O, Y), dok se kod pojedinih klasa javljaju veće greške u klasifikaciji (slova: B, M , N, V). Ovaj obrazac se

Slika 6: SVM matrica konfuzije na celom skupu podataka

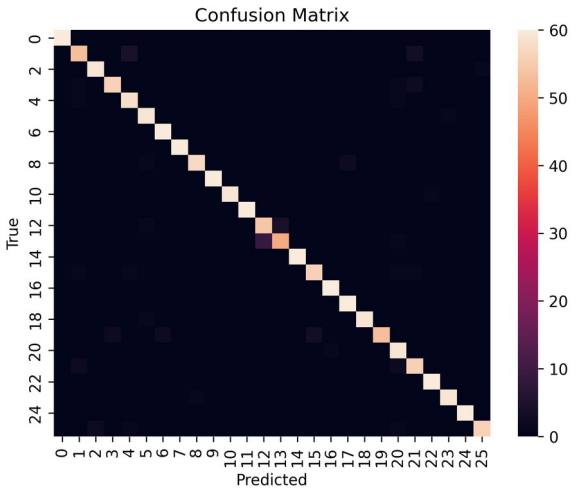

javlja i kod svih posmatranih transformacija SVM modela, što sugeriše da greške nisu slučajne, već su verovatno posledica fonetske sličnosti između određenih klasa koje model teže razlikuje.

Tabela 12: SVM detaljna analiza klasa na celom skupu podataka

Class	Precission	Recall	f1_score
A	1.00	1.00	1.00
B	0.91	0.88	0.90
C	0.97	0.98	0.98
D	0.97	0.93	0.95
E	0.91	0.97	0.94
F	0.95	0.98	0.97
G	0.97	1.00	0.98
H	1.00	1.00	1.00
I	0.98	0.95	0.97
J	1.00	1.00	1.00
K	1.00	0.98	0.99
L	1.00	1.00	1.00
M	0.86	0.92	0.89
N	0.93	0.83	0.88
O	1.00	1.00	1.00
P	0.95	0.93	0.94
Q	0.98	1.00	0.99
R	0.97	1.00	0.98
S	1.00	0.98	0.99
T	1.00	0.88	0.94
U	0.89	0.98	0.94
V	0.90	0.93	0.92
W	0.98	1.00	0.99
X	0.98	0.98	0.98
Y	1.00	1.00	1.00
Z	0.98	0.93	0.96

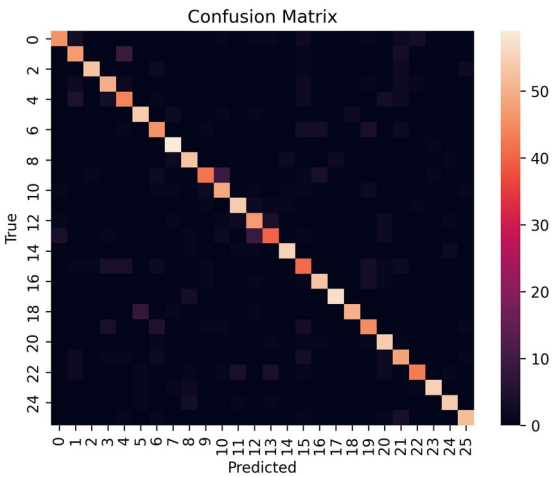

Matrica konfuzije DTC modela nad celim skupom podataka je data na Slici 7. Iako je većina polja van dijagonale niske vrednosti uočava se da broj polja s nešto većim vrednostima nije zanemarljiv. Takođe u ovom slučaju dijagonala ima znatno manje vrednosti koje su blizu maksimalnim. Dodatno, analizom classification report-a (Tabela 13) se vidi da pored slova R i X koja ostvaruju veoma visoke vrednosti svih metrika, veći broj klasa ima primetno niže rezultate. Posebno slabije rezultate ostvaruje u klasama E, N i P, dok ukupno 16 klasa ima niži F1-score od najniže vrednosti kod SVM-a. Kod SVM modela se vidi da su vrednosti visoke za sve klase jer on formira jasne granice između klasa, pa se uzorci lakše razdvajaju. Kod DTC modela to nije slučaj zato što odluke zavise od uzastopnog grananja po atributima, pa male razlike u podacima mogu da dovedu do pogrešnih podela i samim tim do lošijeg razdvajanja pojedinih klasa.

Tabela 13: DTC detaljna analiza klasa na celom skupu podataka

Class	Precission	Recall	f1_score
A	0.88	0.77	0.82
B	0.76	0.78	0.77
C	0.96	0.88	0.92
D	0.79	0.83	0.81
E	0.71	0.73	0.72
F	0.83	0.90	0.86
G	0.73	0.77	0.75
H	0.88	0.98	0.93
I	0.83	0.88	0.85
J	0.86	0.70	0.77
K	0.75	0.82	0.78
L	0.87	0.90	0.89
M	0.73	0.80	0.76
N	0.77	0.67	0.71
O	0.93	0.92	0.92
P	0.63	0.68	0.66
Q	0.87	0.88	0.88
R	0.97	0.95	0.96
S	0.96	0.83	0.89
T	0.75	0.75	0.75
U	0.79	0.90	0.84
V	0.71	0.80	0.75
W	0.88	0.72	0.79
X	0.96	0.92	0.94
Y	0.92	0.90	0.91
Z	0.91	0.87	0.89

Može se zaključiti da različite transformacije podataka ne menjaju značajno međusobni odnos performansi modela, ali utiču na njihove vrednosti. SVM se pokazao kao najstabilniji model u svim eksperimentima, a Random Forest i KNN takođe ostvaruju visoke i konzistentne rezultate. PCA dovodi do blagog pada performansi kod većine modela, dok feature selection u nekim slučajevima omogućava zadržavanje ili blago poboljšanje tačnosti uz smanjenje broja atributa. Ovi rezultati ukazuju da izbor modela ima veći uticaj na krajnju tačnost nego sama transformacija podataka, ali da i redukcija dimenzionalnosti može doprineti stabilnosti modela.

5 Zakljucak

U ovom radu sproveli smo analizu ISOLET skupa podataka i primenu pet klasifikacionih algoritama u različitim transformisanim prostorima. Tokom rada izvršili smo pripremu i analizu podataka, uključujući proveru balansiranosti klasa, nedostajućih vrednosti, analizu outliera, standardizaciju i metode redukcije dimenzionalnosti.

Sprovedeni eksperimenti pokazali su da je moguće značajno smanjiti dimenzionalnost podataka uz zadržavanje visokih performansi klasifikacije, kao i da izbor klasifikacionog modela ima uticaj na konačne rezultate.

Iako su ostvareni veoma dobri rezultati, postoji prostor za dalja istraživanja i unapređenja. Budući rad može uključivati primenu neuronskih mreža, dodatnu optimizaciju hiperparametara i ispitivanje drugih metoda redukcije dimenzionalnosti i selekcije atributa.

6 Literatura

1. ISOLET Dataset, UCI Machine Learning Repository.
   http://archive.ics.uci.edu/dataset/54/isolet
2. Materijali sa predmeta „Istraživanje podataka 1“, Matematički fakultet, Univerzitet u Beogradu.
   https://github.com/MATF-istrazivanje-podataka-1/materijali/tree/main
3. Materijali sa predmeta „Istraživanje podataka 2“, Matematički fakultet, Univerzitet u Beogradu.
   https://github.com/MarijaRistic23/Istrazivanje-podataka-2